

Arquitetura de Computadores

Angelica Nakagawa Lima
angelica.lima@ibta.edu.br

Calendário da Disciplina com atividades e avaliações

Calendário

- ~~13/05 - Principais grandezas elétricas. Sistema de distribuição de energia elétrica e transformadores. Conceitos de hardware, software e peopleware.~~
- ~~20/05 - Unidade Central de Processamento. Microprocessadores.~~
- 27/05 - Discos rígidos. Placas controladoras de HD.
- 03/06 - Monitores de vídeo. Impressoras.
- 08/06 - Encerramento das disciplinas EAD
- 10/06 - PM/Revisão
- 17/06 - Prova


Paralelismo e pipeline

No episódio anterior...




Unidade Central de Processamento (Processador)

Arquitetura Von Neumman



Unidade Central de Processamento (Processador)



Organização básica do computador:



Unidade Central de Processamento (Resumo)

Definição de CPU:

- ✓ Entidade de hardware centralizadora, coordenadora e gerenciadora de todos os recursos do sistema computador, responsável pelas funções de lógica, aritmética e controle do processo.
- ✓ “Cérebro do computador”.




Unidade Central de Processamento (Resumo)

- ✓ Muitas vezes, de forma equivocada, chamamos de CPU o conjunto completo do computador.
- ✓ Em português é o termo é Unidade Central de Processamento: CPU = UCP = Processador.




Unidade Central de Processamento (Resumo)

As atividades realizadas por um processador (suas funções) podem ser divididas em duas grandes categorias:




Função de controle:

- UC – Unidade de controle




Função de Processamento:

- ULA – Unidade de Lógica e Aritmética



Unidade Central de Processamento (Resumo)


Esquema da CPU



Processamento de dados: Paralelismo

Computadores de alto-desempenho são utilizados em diversas áreas:

- ✓ análise estrutural;
- ✓ previsão de tempo;
- ✓ exploração de petróleo;
- ✓ pesquisa em fusão de energia;
- ✓ diagnóstico médico;
- ✓ simulações aerodinâmicas;
- ✓ automação industrial;
- ✓ sensoriamento remoto;
- ✓ engenharia genética;
- ✓ entre outras.



Processamento de dados: Paralelismo

Situação problema: necessidade de computadores cada vez mais rápidos!



X



Processamento de dados: Paralelismo

Situação problema: necessidade de computadores cada vez mais rápidos!



Processamento de dados: Paralelismo

Situação problema: necessidade de computadores cada vez mais rápidos!



A obtenção de alto desempenho não depende somente em utilizar dispositivos de hardware **mais rápidos**, mas também em **melhorias na arquitetura dos computadores e técnicas de processamento.**



Processamento de dados: Paralelismo

Situação problema: necessidade de computadores cada vez mais rápidos!

- ✓ A velocidade dos atuais circuitos não podem aumentar indefinidamente.
- ✓ A velocidade do clock tem aumentado gradativamente.
- ✓ Dissipação de calor é um grande problema.
- ✓ Tamanho dos transístores continua a diminuir: cada transístor terá um número tão pequeno de átomos que os efeitos da mecânica quântica podem tornar-se um grande problema.

Processamento de dados: Paralelismo


Paralelismo

- ✔ Os projetistas de hardware estão sempre tendo desafios para melhorar cada vez mais a performance dos computadores.
- ✔ Uma das maneiras de se obter isso é fazendo com que os processadores executem tarefas cada vez mais rápido, aumentando a velocidade do clock.
- ✔ Porém, existe um limite tecnológico para isso.
- ✔ Os projetistas voltam-se então para o paralelismo (executando duas ou mais operações ao mesmo tempo), como forma de obter uma performance melhor.

Processamento de dados: Paralelismo

Paralelismo

- ✔ Arquitetura de computador moderna possui como um dos seus princípios maximizar a taxa de execuções de instruções.
- ✔ Conceito de MIPS (millions of instructions per second): quantas instruções o processador pode iniciar por segundo.



Processamento de dados: Paralelismo


Paralelismo

- ✓ O paralelismo pode ocorrer em dois níveis:
 - **Nível das instruções.**
 - **Nível do processador.**
- ✓ No primeiro caso, o paralelismo é explorado dentro das instruções individuais, de maneira a conseguir que a máquina execute mais instruções por segundo.
- ✓ No segundo caso, dois ou mais processadores trabalham juntos na solução de um problema.

Paralelismo no nível da instrução


Ciclo de instrução:

- Baseado na proposta da arquitetura de **Von Neumann**.
- O ciclo pode ser representado por meio do fluxo ao lado.
- O contador de instruções (CI) indica a sequência de execução, isto é, controla o fluxo de execução das instruções.



Paralelismo no nível da instrução

- ✓ Este procedimento segue a arquitetura proposta por von Neumann.
- ✓ Para calcular o tempo total de execução da instrução, podemos resumir da seguinte forma:



- ✓ Ciclo de busca = leitura da instrução, incremento do CI
- ✓ Ciclo de execução = decodificação, busca do operando, execução da operação.
- ✓ $T = \text{tempo de execução da instrução} = T_1 + T_2$

Paralelismo no nível da instrução

Vamos fazer uma analogia com uma hipotética fábrica sequencial de automóveis, que funcionaria da seguinte maneira:

- Primeiro a carroceria (gastaria um tempo T_1);
 - Depois o motor (T_2);
 - Em seguida as rodas (T_3);
 - Depois parte elétrica (T_4);
 - Os bancos e tapeçaria (T_5);
 - E o acabamento final (T_6).
-
- ✓ O tempo total (T) seria: $T = T_1 + T_2 + T_3 + T_4 + T_5 + T_6$
 - ✓ Somente com a total conclusão de um carro (tempo T) é que outro automóvel iniciaria a montagem.

Paralelismo no nível da instrução

Pipeline

- ✓ Henry Ford no início do século XX, dividiu o processo de fabricação em estágios independentes
- ✓ Este método foi denominado de linha de montagem, ou **pipeline**.
- ✓ Nele um item pode iniciar sua fabricação antes que um item anterior termine sua montagem.
- ✓ Em computação os projetistas adotaram metodologia semelhante. O **pipeline** apresenta 2 aspectos:
 - Divisão da execução de instruções em várias partes (estágios) de realização independente um do outro;
 - Uma nova instrução inicia sua execução antes da instrução anterior concluir seu processo

Paralelismo no nível da instrução

Pipeline

- ✓ É semelhante a uma linha de produção...



Paralelismo no nível da instrução

Pipeline

- ✓ É semelhante a uma linha de produção...



Paralelismo no nível da instrução

Pipeline

- ✓ É semelhante a uma linha de produção...



Paralelismo no nível da instrução

Pipeline



Vejamos um
outro exemplo
mais próximo do
cotidiano

Muitas tarefas do nosso dia-a-dia
utilizam-se de conceitos que veremos a
seguir.


Paralelismo no nível da instrução

Vamos estudar o exemplo da lavanderia:

- ✓ Ana, Bruno, Carla e Daniel têm roupas sujas para serem lavadas, secadas, passadas e guardadas. Nesse processo, considere que:
 - Lavar a roupa gasta um tempo $T_1 = 30$ minutos;
 - Secar a roupa gasta um tempo $T_2 = 40$ minutos;
 - Passar a roupa gasta um tempo $T_3 = 30$ minutos;
 - Guardar a roupa gasta um tempo $T_4 = 20$ minutos.
- ✓ O tempo total do processo (T) seria: $T = T_1 + T_2 + T_3 + T_4$
- ✓ Somente com a conclusão total de um processo de lavagem (T) é que outro seria iniciado.

Paralelismo no nível da instrução


Exemplo da lavanderia sequencial:



Nesse processo sequencial, cada lavagem completa gasta 2 horas e, portanto, o ciclo todo tem duração de 8 horas!

Paralelismo no nível da instrução

Exemplo da lavanderia não sequencial (pipeline):



Nesse novo processo, o ciclo todo tem duração de apenas 4 horas

Paralelismo no nível da instrução



Pipeline:

- ✔ É uma forma de obter uma alta performance ao “partir” o processamento de uma instrução numa série de estágios, que são ligados como as estações numa linha de montagem.
- ✔ À medida que as instruções fluem ao longo do pipeline, o hardware em cada estágio realiza algum processamento, até que as instruções que deixam o pipeline são completamente processadas.
- ✔ A alta performance é obtida pelo paralelismo no processamento das várias instruções ao mesmo tempo, cada uma em diferentes estágios do pipeline.

Paralelismo no nível da instrução

No exemplo da lavanderia, observe que:


- ✓ O pipeline não reduz o tempo gasto para completar uma instrução individualmente.
- ✓ Melhora o throughput de todo o trabalho.
- ✓ A taxa do pipeline é limitada pelo estágio mais lento.



Paralelismo no nível da instrução

A execução de uma instrução em um computador pode ser resumida em cinco passos (estágios) principais:

- ✓ Busca de instrução (BI).
- ✓ Decodificação de instrução (DI).
- ✓ Busca de operando (BO).
- ✓ Execução da instrução (EI).
- ✓ Gravação.



Paralelismo no nível da instrução

- ✔ Para implementar pipelining, os projetistas dividem o caminho de dados de um processador em seções e colocam latches em cada seção.
- ✔ No início de cada ciclo, os latches leem as suas entradas e copiam para suas saídas.
- ✔ Desta forma, o caminho de dados é dividido em diversas seções.
- ✔ Cada uma das quais têm um ciclo de relógio, uma vez que uma instrução não pode passar através de um latch até que o próximo ciclo seja iniciado.
- ✔ Latch é um elemento de memória (buffer).


Paralelismo no nível da instrução

Funcionamento de um pipeline de 5 estágios:


- ✓ Estágio 1: busca a instrução da memória e armazena num buffer até chegar a hora de executá-la.
- ✓ Estágio 2: ocorre a decodificação da instrução, determinando tipo e operandos.
- ✓ Estágio 3: ocorre a busca dos operandos na memória ou nos registradores.
- ✓ Estágio 4: tem-se a execução.
- ✓ Estágio 5: o resultado do processamento é escrito num registrador.

Paralelismo no nível da instrução

Funcionamento de um pipeline de 5 estágios:



(a)



(b)

Paralelismo no nível da instrução

Funcionamento de um pipeline de 5 estágios:

- ✓ No 1º ciclo de clock:
 - O estágio S1 está na instrução 1 (I1), buscando-a na memória.
- ✓ No 2º ciclo de clock:
 - O estágio S2 decodifica a instrução 1 (I1);
 - O estágio S1 busca instrução 2 (I2).
- ✓ No 3º ciclo de clock:
 - O estágio S3 busca os operandos da instrução 1 (I1),
 - O estágio S2 decodifica a instrução 2 (I2);
 - O estágio S1 busca uma terceira instrução (I3).

Paralelismo no nível da instrução

Funcionamento de um pipeline de 5 estágios:

- ✔ No 4º ciclo de clock:
 - O estágio S4 executa a instrução 1 (I1);
 - O estágio S3 busca os operandos da instrução 2 (I2);
 - O estágio S2 decodifica a instrução 3 (I3);
 - O estágio S1 busca uma quarta instrução (I4),
 - O demais estágios trabalham nas instruções subsequentes.
- ✔ No 5º ciclo de clock:
 - As instruções 2 a 5 estão no pipeline;
 - A instrução 1 já está completa.

Paralelismo no nível da instrução

A duração do ciclo em um processador com pipeline é baseada na seguinte fórmula:

$$\text{Duração do ciclo}_{\text{com pipeline}} = \frac{\text{Duração do ciclo}_{\text{sem pipeline}}}{\text{Número de estágios de pipeline}} + \text{latência do latch}$$

Exemplo:

Um processador sem pipeline tem uma duração de ciclo de 25 ns. Qual a duração do ciclo de uma versão deste processador com pipeline de 5 estágios divididos homogeneamente, se cada latch tem uma latência de 1ns?

$$\text{Duração do ciclo com pipeline} = (25/5) + 1 \Rightarrow 6 \text{ ns}$$

Paralelismo no nível da instrução

Conclusões:

- ✓ Execução de mais de uma instrução ao mesmo tempo pela CPU, a fim de aumentar a quantidade de instruções por ciclo do relógio
- ✓ Realizar mais de uma atividade ao mesmo tempo
- ✓ Exemplo: em um jogo é processada a imagem e realizados os cálculos matemáticos.
- ✓ Menor gasto de memória



Paralelismo no nível da instrução

Conclusões:

- ✓ Nenhum estágio fica ocioso e várias instruções podem ser processadas ao mesmo tempo.
- ✓ O pipeline **não** reduz o tempo de execução de uma instrução, mas agiliza o processo de um conjunto de tarefas.


Toda vez as mulheres reclamarem que os homens não conseguem fazer duas coisas ao mesmo tempo digam: mulheres os homens não têm pipeline.



Paralelismo no nível do processador

Aumento do número de processadores trabalhando num mesmo problema.

Vários processadores Trabalhando no mesmo problema



Paralelismo no nível do processador

- ✔ Inicialmente, os computadores eram vistos como máquinas sequenciais, onde a CPU executava as instruções de um programa de cada vez.
- ✔ Com a implementação de sistemas com múltiplos processadores, o conceito de paralelismo pôde ser expandido a um nível mais amplo.
- ✔ Sistemas com múltiplos processadores são arquiteturas que possuem duas ou mais CPUs interligadas e que funcionam em conjunto na execução de tarefas independentes ou no processamento simultâneo de uma mesma tarefa.

Paralelismo no nível do processador

- ✔ Os primeiros sistemas surgiram na década de 1960.
- ✔ Por muito tempo, tais sistemas foram utilizados para processamento científico.
- ✔ O mercado corporativo começou a utilizar sistemas com múltiplos processadores na década de 1980.
- ✔ O objetivo era melhorar o desempenho das aplicações comerciais e reduzir o tempo de resposta dos usuários interativos.
- ✔ Posteriormente, as empresas reconheceram nesse tipo de sistemas uma maneira de aumentar a confiabilidade, escalabilidade e a disponibilidade.

Paralelismo no nível do processador

Atualmente, a maioria dos servidores de banco de dados, servidores de arquivos e servidores Web, utilizam sistemas com múltiplos processadores.

- ✔ Desempenho:

- O aumento de desempenho pode ser observado pelo maior throughput do sistema, redução do tempo de resposta e menor tempo de processamento das aplicações.

- ✔ Escalabilidade:

- Capacidade de adicionar novos processadores.
- Com múltiplos processadores é possível ampliar a capacidade de computação apenas adicionando-se novos processadores.

Paralelismo no nível do processador

- ✓ Os processadores tradicionais são processadores do tipo “single core”, ou seja, um único núcleo.
- ✓ Tecnologia Multicore:
 - Processador com mais de um núcleo;
 - **Exemplo:** um processador “dual core”, tem dois núcleos embutidos num só processador.
 - Desta forma, dois programas diferentes podem ser executados ao mesmo tempo, um em cada núcleo.
 - A nanotecnologia permite a produção deste tipo de processador
 - 1 nanômetro = 10^{-6} mm (1 milionésimo de milímetro)

Paralelismo no nível do processador

Para fins de comparação: cabelo humano (90.000 nm); uma bactéria 2.000 nm.

Se os processadores ainda tivessem o tamanho que tinham
em 1971



Um smartphone teria o tamanho de uma **geladeira**.




Cada transistor usaria **4 mil vezes** mais energia.



E seriam **100 mil vezes** mais caros.

Paralelismo no nível do processador

Exemplo: Intel Core i7



Paralelismo no nível do processador


Processamento fortemente acoplado:

- ✓ quando duas ou mais CPU ou dois elementos de processamento estão perto um do outro.
- ✓ Têm alta largura de banda.
- ✓ O atraso é baixo e são próximos computacionalmente.

Processamento fracamente acoplado:

- ✓ Quando estão longes um do outro.
- ✓ Têm baixa largura de banda.
- ✓ Alto atraso e são remotos computacionalmente.

Paralelismo no nível do processador




* Thread é a tarefa que um determinado programa realiza.

O que são threads

A thread é uma divisão do processo principal de um programa e definem como um processador funciona, recebendo e executando instruções.

Vamos tomar como exemplo o processador Intel Core i3 2377M

Essa CPU pode trabalhar com dois processos indivisíveis simultaneamente (um em cada núcleo) ou com até quatro linhas de execução (threads) - as quais podem ou não ser de um mesmo processo.



Memória

O que é memória?

Analogia: Biblioteca

- ✔ Para que serve a biblioteca / bibliotecária?



O que é memória?

Simples: armazena/recupera dados numéricos

- ✓ Para uso posterior!


Na prática...

- ✓ Dispositivo físico capaz de armazenar a configuração elétrica de um “conjunto de fios”.
- ✓ Configuração elétrica: padrão de bits
- ✓ Logo, memória armazena dados




Como funciona a memória?

Como se acende uma lâmpada?



Como funciona a memória?


Como se acende uma lâmpada?



Se passar corrente a luz
acende!!


Como funciona a memória?

Como acender uma lâmpada de várias?




Como funciona a memória?

Como acender uma lâmpada de várias?




Como funciona a memória?

Como acender uma lâmpada de várias?




Como funciona a memória?

Como acender uma lâmpada de várias?



Como funciona a memória?

Como acender uma lâmpada de várias?



Endereços

Seletor de
Endereços

Como funciona a memória?


Leitura da Memória



Mas o que isso
tem a ver com a
memória???


Funcionamento simplificado

Leitura da Memória




Funcionamento simplificado

Leitura da Memória



Funcionamento simplificado

Escrita na Memória



Tipos de dispositivos de armazenamento

Eletrônicos

- ✓ São rápidas pois não apresentam partes móveis.
- ✓ São ideais como memória principal do computador.

Eletromecânicos

- ✓ Possuem partes móveis, portanto são lentas.
- ✓ São exemplos: discos, fitas magnéticas.
- ✓ São utilizadas como memórias auxiliares.
- ✓ Apresentam uma capacidade gigantesca de armazenamento.




X



Tipos de dispositivos de armazenamento

Memória principal


- ✓ Pode-se imaginar a memória principal como uma grade (ou tabela), com uma célula em cada interseção.
- ✓ Dependendo do computador cada célula pode armazenar um byte, dois bytes, ou mais.
- ✓ Cada célula tem um endereço único, que dá sua posição na grade.



Tipos de dispositivos de armazenamento

Memória principal

- ✓ Pode-se imaginar a memória principal como uma grade (ou tabela), com uma célula em cada interseção.
- ✓ Dependendo do computador cada célula pode armazenar um byte, dois bytes, ou mais.
- ✓ Cada célula tem um endereço único, que dá sua posição na grade.




Tipos de dispositivos de armazenamento

Memória principal

- ✓ Na prática, pode haver diversas destas grades e, neste caso, o endereço especifica o número da grade, bem como da linha e da coluna na mesma.



Características das memórias



Características de memória

Tempo de Acesso:

- ✓ Indica o tempo gasto pela memória para disponibilizar uma informação, após determinada posição ter sido endereçada.
- ✓ Em outras palavras é o tempo decorrido entre o instante que a operação foi iniciada, até que a informação seja transferida.
- ✓ Quanto mais veloz for a memória, menor o tempo de acesso e vice-versa.



Características de memória

Capacidade:

- ✓ É a quantidade de informação que pode ser armazenada.

Exemplos:

- ✓ Alguns poucos bits nos registradores.
- ✓ Terabytes nos discos rígidos.



Características de memória

Temporalidade:

- ✓ É o conceito de permanência da informação num dado tipo de memória.

Exemplos:

- ✓ Discos rígidos são capazes de manter as informações por anos.
- ✓ Registradores mantêm as informações por nanossegundos, apenas enquanto a ULA executa uma determinada operação.



Características de memória

Custo:


- ✓ Varia em função de diversos fatores.
- ✓ Principalmente devido a tecnologia empregada.
- ✓ Normalmente é tomado com base na relação:
 - $\text{Custo} \times \text{Capacidade de armazenamento}$.




Características de memória

Volatilidade:

- Memória volátil é aquela que perde a informação quando é desligada.
- Memória não volátil, tem por característica básica manter as informações armazenadas, mesmo quando não energizadas.




X



Características de memória

Com base nestas características:

- Tempo de Acesso;
 - Capacidade;
 - Temporariedade;
 - Custo;
 - Volatilidade.
- ✓ É possível hierarquizar as diferentes memórias existentes.
 - ✓ Esta hierarquia pode ser representada através de uma pirâmide.



Hierarquia de memória



No topo:

- Baixo tempo de acesso (alta velocidade).
- Baixa capacidade.
- Baixa temporariedade.
- Alto Custo.




Na base:

- Alto tempo de acesso (baixa velocidade).
- Alta capacidade.
- Alta temporariedade.
- Baixo Custo.



Hierarquia de memória

- Custo alto
- Velocidade alta
- Capacidade baixa




- Custo baixo
- Velocidade baixa
- Capacidade alta




Hierarquia de memória



Hierarquia de memória



Hierarquia de memória




Tecnologia de fabricação

Diz respeito a tecnologia empregada na fabricação da memória:

Memória de semicondutores: fabricadas com circuitos eletrônicos baseados em semicondutores.

- ✓ Alta Velocidade.
- ✓ Alto Custo.
- ✓ **Exemplos:** Registradores, Ram e Cache.



Tecnologia de fabricação

Diz respeito a tecnologia empregada na fabricação da memória:

Memória de meio magnético: são dispositivos como fitas e discos rígidos que armazenam as informações sob a forma de marcas magnéticas.

- ✓ Dispositivos com componentes eletromecânicos.
- ✓ Velocidade mais baixa.
- ✓ Custo mais baixo.
- ✓ Maior capacidade.




Tecnologia de fabricação

Diz respeito a tecnologia empregada na fabricação da memória:

Memória de meio óptico: são dispositivos como CDs, DVDs e Blu-ray, que armazenam as informações através do uso de feixes de luz.





Memória RAM



Memória principal

Memória Principal – RAM (Random Access Memory)



- ✓ **Memória de acesso aleatório:** é uma memória de leitura e gravação.
- ✓ É uma memória volátil, isto é, perde o seu conteúdo quando lhe retiramos a alimentação elétrica.
- ✓ Tem por propósito o armazenamento temporário de dados.
- ✓ É composta por unidades de acesso chamadas células.
- ✓ Cada célula é composta por um determinado número de bits.



Memória principal

Organização da Memória RAM:

- 1) **Palavra:** valor em bits da unidade de informação do processador.
Exemplo: 8 bits, 32 bits, 64 bits.
- 2) **Endereço ou Posição:** identificação da área da memória que será acessada.
- 3) **Conteúdo:** a partir do endereço inicial é o conteúdo (dados) que serão manipulados.





Memória principal

Organização da Memória RAM:

4) Unidade de armazenamento: grupo de bits que pode ser identificado e localizado individualmente. Normalmente expressa em bytes.


5) Unidade de transferência: quantidade de bits que é transferida em uma operação de leitura ou escrita na memória. Normalmente expressa em bits.



Memória principal

Capacidade da memória


- ✓ A memória RAM é um conjunto de **N** células, cada qual com **M** bits.
- ✓ Como o endereçamento é feito por células podemos dizer que **N**, também é a capacidade de endereços.



Memória principal

Capacidade da memória

- ✓ A memória RAM é um conjunto de **N** células, cada qual com **M** bits.
- ✓ Como o endereçamento é feito por células podemos dizer que **N**, também é a capacidade de endereços.



Memória principal

Capacidade da memória

Sendo assim, **N** representa a capacidade da memória em quantidade de endereços, enquanto **M** representa a quantidade de bits que pode ser armazenada em cada célula;

O total de bits (**T**) é dado então por:

$$T = N * M$$

Exemplo: se tivermos 16 endereços de memória com células de 8 bits, teremos:

$$T = 16 * 8$$

$$T = 128 \text{ bits.}$$

Memória principal

Capacidade da memória

- ✓ Os endereços também são representados em bits, então $N = 2^L$, no qual L é a quantidade bits de endereço.
- ✓ No exemplo anterior, $N=16$, portanto:
 $16 = 2^L$
 $L = 4$ bits.

Aplicação

1- Uma memória principal (RAM) tem espaço máximo de endereçamento de 2K. Cada célula pode armazenar 16 bits.

- a) Qual o total de bits que podem ser armazenados nesta memória?
- b) Qual o tamanho de cada endereço?

2- Uma RAM é fabricada com a possibilidade de armazenar 256 Kbits e cada célula tem o tamanho de 8 bits.

- a) Qual o tamanho de cada endereço?
- b) Qual o total de células?

Respostas: 1- a) Capacidade da Memória Principal = 32K bits

b) Total de bits do Endereço = 11 bits

2- a) Total de bits do Endereço = 15 bits


b) Total de células da Memória Principal = 32K células

Características básicas dos tipos de memória

Tipo	Localização	Volátil?	Velocidade	Capacidade de armazenamento	Custo por bit
Registradores	Processador	Sim	Muito alta (opera na velocidade do processador)	Muito baixa (bytes)	Muito alto
Cache	Processador	Sim	Alta (opera na velocidade do processador)	Baixa (kb)	Alto
Principal	Placa-mãe	RAM – sim ROM – não	Depende do tipo de memória instalada	Média (MB)	Médio (tem caído muito)
Secundária	HD, CD... entre outras	Não	Baixa (lenta)	Alta (GB)	Baixo (tem caído muito)


Outros tipos de Memória

Registradores



Registradores


- ✔ O processador busca dados e instruções de onde estiverem armazenadas e os deposita temporariamente em seu interior para que possa realizar as operações solicitadas utilizando seus demais componentes (análogo à função memória de uma calculadora).
- ✔ Os conceito de registrador surgiu dessa necessidade do processador de armazenar temporariamente dados intermediários durante um processamento.



Registradores

- ✔ Os registradores são dispositivos de **armazenamento temporário** (volátil), **localizados no interior do processador (CPU)**.
- ✔ Por causa da tecnologia utilizada, os registradores são um tipo de **memória extremamente rápida e bastante cara**. Por esse motivo, sua disponibilidade em um computador é muito limitado.
- ✔ Cada registrador possui capacidade para manter apenas um dado (**uma palavra**).


Palavra: valor em bits da unidade de informação do processador. **Exemplo:** 8 bits, 32 bits, 64 bits



Registradores


Os registradores podem ser organizados em:

- ✓ **Registradores visíveis para o usuário:** permitem ao programador fazer acesso.
- ✓ **Registradores de controle e de estado:** usados pela UC para controlar a operação da CPU e por programas privilegiados do sistema operacional.



Registradores


- ✓ Um tipo importante de registradores visíveis ao usuário é o registrador de dados.
- ✓ Como o nome indica, ele não pode conter valores empregados no cálculo de endereços de operandos, apenas de dados.
- ✓ Todo dado transferido para ULA é armazenado nesse registrador.
- ✓ Além disso, o resultado de uma operação feita na ULA precisa ser armazenado, de modo que possa ser reutilizada ou transferida para a memória.



Registradores

Os registradores de controle e estado são os vários registradores da CPU que são empregados para controlar a operação da CPU:


- ✔ **contador de programa (PC):** que contém o endereço da instrução a ser buscada;
- ✔ **registrador de instrução (IR):** que contém a última instrução buscada;
- ✔ **registrador de endereçamento à memória (MAR):** que contém o endereço de uma posição de memória;
- ✔ **registrador de armazenamento temporário de dados (MBR):** que contém os dados a serem escritos ou lidos na memória.




Registradores

Em resumo, os registradores:

- ✓ Devido a sua alta velocidade de transferência, ficam no topo da pirâmide.
- ✓ Possuem capacidade de armazenamento limitada.
- ✓ Seu custo é elevado.
- ✓ Ficam localizados no interior do processador.
- ✓ São divididos em duas categorias: visíveis ao usuário e de controle e estado.




Memória ROM



Memória ROM

ROM – Read Only Memory

- ✓ Memória **somente de leitura**, usadas para guardar instruções e dados que não vão mudar durante o processo de operação do sistema.
- ✓ **Não é volátil**, ou seja, os dados nelas armazenados não se perdem quando o equipamento é desligado.
- ✓ Todo computador tem algum tipo de memória ROM.
- ✓ A memória ROM, evoluiu com o tempo dando origem a diversas denominações.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

Mask-ROM

- ✓ Tipo mais comum de ROM.
- ✓ Normalmente denominada somente ROM.
- ✓ Dados e instruções inseridos no momento da fabricação.
- ✓ Uma vez pronta, não pode ser mais alterada.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

PROM – Programmable ROM

- ✓ Neste tipo de ROM, o programa não é inserido no momento da fabricação.
- ✓ A PROM é fabricada “em branco”.
- ✓ Num momento posterior o programa é inserido na pastilha.
- ✓ Este processo é denominado “queima” da pastilha.
- ✓ Uma vez que os dados são inseridos, não podem ser mais alterados.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

EPROM – Erasable Programmable ROM

- ✓ Neste tipo de ROM, os dados já inseridos podem ser alterados.
- ✓ Na verdade, é um processo mais complexo que uma simples alteração.
- ✓ Os dados inseridos podem ser apagados, através do uso de uma luz ultravioleta, aplicada por meio da janela do chip.
- ✓ Uma vez que os dados foram apagados, este tipo de ROM pode ser novamente programado.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

EEPROM – Electrically EPROM

- ✓ A EEPROM foi desenvolvida no início dos anos 1980, e apresentada ao mercado como um aperfeiçoamento da ideia da PROM.
- ✓ Neste tipo de ROM, a inserção e a exclusão dos dados pode ser controlada eletronicamente pelo processador. Isto significa portanto, que pode ser alterada por software.
- ✓ Também pode ser denominada de **EAROM** ou Electrically Alterable ROM.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

EEPROM – Electrically EPROM

- ✓ Uma aplicação típica de EEPROM consiste na programação de teclas de um teclado.
- ✓ A função de cada tecla é definida numa tabela e gravada numa EEPROM que forma o circuito dentro do teclado.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

Memória FLASH

- ✓ Similar a EEPROM.
- ✓ Porém, muito mais veloz, daí vem a denominação FLASH.
- ✓ Isto se dá pelo seguinte motivo:
 - A EEPROM apaga a memória, byte a byte.
 - A Flash, pode ser apagada em blocos de bytes, portanto, muito mais rapidamente.
- ✓ Pela velocidade de funcionamento e versatilidade, a Memória Flash é utilizada em diversos dispositivos.




Memória ROM

A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

Memória FLASH


- ✔ Um tipo de aplicação comum das memórias Flash-ROM é o seu uso em computadores, que possuem nessa memória três programas principais: a BIOS (Basic Input Output System – Sistema Básico de Entrada e Saída), o POST (Power On Self Test – Autoteste de ligação) e SETUP (programa de configuração do hardware instalado no computador)
- ✔ Os fabricantes de placas mãe desenvolvem versões de software que podem ser atualizadas para corrigir problemas ou implantar novas características de funcionamento de suas placas.



Memória ROM

Nos computadores, diversos softwares não podem ser apagados na ausência de energia e, portanto, são armazenados em memórias ROM. Desses, podemos citar três principais:

- ✔ **BIOS (Basic Input Output System):** ou Sistema Básico de Entrada e Saída, é responsável por ensinar o processador da máquina a operar com os dispositivos básicos de entrada e saída;
- ✔ **POST (Power On Self Test):** Autoteste ou programa de verificação e teste que se executa após a ligação do computador, realizando diversas ações sobre o hardware (ex.: contagem de memória)
- ✔ **SETUP:** Programa que altera os parâmetros armazenados na memória de configuração (CMOS)




Memória ROM


A memória ROM, evoluiu com o tempo dando origem a diversas denominações:

Memória FLASH

- ✓ Atualmente, celulares e smartphones também implementam essa tecnologia que permite atualizações de software.



Memória cache



Memória cache

Problema:

- ✓ O ciclo de memória atualmente é bem mais demorado do que o período de tempo que a CPU gasta para realizar uma operação na ULA.
- ✓ Portanto, fica claro que a duração da execução de um ciclo de instrução é bastante afetada pela demora dos ciclos de memória.
- ✓ De modo geral, a CPU ficaria muito tempo ociosa, acarretando uma baixa produtividade do sistema.


O elo entre a memória principal (RAM) e a CPU tem um ponto frágil: o ciclo de instrução é muito mais rápido do que o **ciclo de memória**.



Memória cache

Exemplo:

- ✓ Numa operação de soma de dois operandos a CPU gasta 2 ns para realizar a operação na ULA.
- ✓ A leitura de cada um dos operandos leva cerca de 100 ns.
- ✓ Esta diferença se transforma num GARGALO.
- ✓ Este é conhecido como GAP de velocidade entre a CPU e a RAM.



Memória cache


Qual foi a solução encontrada pelos projetistas de sistemas ?

- ✓ Na busca de uma solução para o problema criou-se um mecanismo, que consiste na inclusão de um dispositivo de memória entre a CPU e a memória principal;
- ✓ Este mecanismo é denominado memória cache;
- ✓ Sua função é acelerar a transferência de dados entre CPU/memória, aumentando o desempenho do sistema.

A memória cache surgiu quando se percebeu que as memórias não eram mais capazes de acompanhar o processador em velocidade.




Memória cache



Memória cache


- ✓ A memória cache é do tipo SRAM (Static Random Access Memory).
- ✓ A memória RAM é do tipo DRAM (Dynamic Random Access Memory).
- ✓ As memórias SRAM apresentam:
 - Menor tempo de acesso
 - Custo mais elevado



Memória cache

A ideia básica de uma cache é simples:


- ✓ Os dados e/ou instruções usados com mais frequência são mantidos na Memória Cache (MC);
- ✓ Quando a CPU precisa dos dados e /ou instruções, ela examina em primeiro lugar na MC;
- ✓ Se estiver, este fato é denominado acerto (ou **hit**);
- ✓ O dado é transferido da MC para o processador em uma velocidade muito maior que a relação entre memória principal e CPU.



Memória cache

A ideia básica de uma cache é simples:

- ✓ Se os dados não estiverem na MC este fato é denominado falta (ou miss);
- ✓ Nesse caso, os dados e/ou instruções são transferidos da memória para os registradores, mas, ao mesmo tempo também carregará (cópia) dos dados e/ou instruções para a MC;
- ✓ Da próxima vez que ela precisar dos mesmos dados e/ou instruções, eles serão encontrados na cache, economizando tempo.



Memória cache

- ✓ Naturalmente, a operação decorrente de uma falta é muito mais demorada que a de um acerto;
- ✓ O que se deseja, então, é um máximo de acertos (hits) e um mínimo de faltas (misses);
- ✓ Desta forma o sistema terá um bom desempenho;
- ✓ Podemos definir um valor de eficiência da MC pela relação entre os acertos e o total de acessos.

$$E_c = \frac{\text{Acertos (hits)}}{\text{Total de acessos}} * 100$$

Sendo E_c = Eficiência da Cache

Memória cache

Exemplo:

Um determinado sistema de computação possui uma Memória Cache, Memória Principal e processador. Em operações normais, obtêm-se 96 acertos para cada 100 acessos do processador às memórias. Qual é a eficiência do sistema de Memória Cache?


Aplicando-se a fórmula: $E_c = 96/100 = 0,96 * 100 = 96\%$

- ✔ Portanto, se uma fração substancial dos dados e/ou instruções estiverem na MC, o tempo médio de acesso pode ser muito reduzido.
- ✔ Assim, o sucesso ou fracasso depende da fração de dados e/ou instruções que estão na MC.

Memória cache

Conceito de localidade


- ✓ O funcionamento da memória cache pode não parecer funcional, mas através do princípio da localidade, isto se torna possível.
- ✓ O que é princípio da localidade?
- ✓ Programa executável → instruções executadas sequencialmente.
- ✓ Os programas em geral são, em média, executados de forma semelhante, isto é, em blocos de instruções sequenciais.



Memória cache

Conceito de localidade

- ✓ Sendo assim, algumas delas são executadas mais de uma vez em curtos intervalos de tempo, sendo que a este comportamento dos programas em execução, chamou-se de princípio da localidade.
- ✓ Programas tendem a usar o mesmo endereço em um curto espaço de tempo (loops).
- ✓ Assim se um programa acessa uma instrução e/ou dado na memória, há probabilidade que o acesso seguinte seja um dado e/ou instrução subsequente.



Memória cache

Veja o seguinte trecho de um programa em Python:

```
1  contador = 1000
2  while (contador != 0):
3      print(contador)
4      contador = contador - 1
5  else:
6      print("O loop while foi encerrado com sucesso!")
7
```

- ✔ Consideremos que a memória cachê seja capaz de armazenar este simples trecho do programa.
- ✔ Isto significará que em 999 das 1000 vezes que o programa repetirá o loop, o sistema obterá um acerto.
- ✔ Ou seja, uma taxa de acerto da ordem de 99,9%.

Memória cache


Níveis de cache

- ✓ No início → única cache: Uma memória cache colocada entre a RAM e o processador.
- ✓ Caches multinível: Com a evolução das arquiteturas, torna-se possível uma cache no mesmo chip que o processador.
 - Em comparação com uma cache conectada por meio de um barramento externo, a cache no chip reduz a atividade do barramento externo do processador.
 - Portanto, agiliza o tempo de execução e aumenta o desempenho geral do sistema, pois quando a leitura dos dados é efetuada na cache do chip, não existe acesso ao barramento.

Memória cache

Cache multinível

- ✓ Quando existem dois níveis de cache, a cache interna é designada de L_1 (level 1)
- ✓ A cache externa designada com o nível L_2 (level 2).
- ✓ Processadores mais recentes incorporaram a cache L_3 .



Memória cache

Cache multinível

- ✔ O acesso tem início pela cache L1, também denominada cache primária e sendo constituída de elementos com tecnologia SRAM e com velocidade de acesso igual à do processador, acelerando bastante o processamento.
- ✔ Portanto, a memória de nível mais baixo (L1) é a que tem maior velocidade (e também maior custo) e menor capacidade.

Memória cache


Cache multinível

- ✓ O processador sempre procura o dado e/ou instrução na memória de menor nível.
- ✓ Não encontrando na L1, buscará na L2.
- ✓ Se não encontrar, buscará na L3.
- ✓ Desta para a memória RAM e finalmente, não encontrando na RAM irá buscar o dado e/ou instrução no disco.

Memória cache

Exemplo:

- ✓ O Intel Core i7, produzido em novembro de 2008, implementa 04 processadores (núcleos).
- ✓ Cada um com caches L_1 e L_2 dedicadas.
- ✓ Com uma cache L_3 compartilhada.



Memória cache

	Processadores da década de 1990			
	486TM SX	Pentium	Pentium Pro	Pentium II
Introduzido	1991	1993	1995	1997
Velocidade de clock	16–33 MHz	60–166 MHz,	150–200 MHz	200–300 MHz
Largura do barramento	32 bits	32 bits	64 bits	64 bits
Número de transistores	1,185 milhão	3,1 milhões	5,5 milhões	7,5 milhões
Dimensão da tecnologia de fabricação (μm)	1	0,8	0,6	0,35
Memória endereçável	4 GB	4 GB	64 GB	64 GB
Memória virtual	64 TB	64 TB	64 TB	64 TB
Cache	8 kB	8 kB	512 kB L1 e 1 MB L2	512 kB L2

Memória cache

	Processadores recentes			
	Pentium III	Pentium 4	Core 2 Duo	Core i7 EE 4960X
Introduzido	1999	2000	2006	2013
Velocidade de clock	450–660 MHz	1,3–1,8 GHz	1,06–1,2 GHz	4 GHz
Largura do barramento	64 bits	64 bits	64 bits	64 bits
Número de transistores	9,5 milhões	42 milhões	167 milhões	1,86 bilhão
Dimensão da tecnologia de fabricação (nm)	250	180	65	22
Memória endereçável	64 GB	64 GB	64 GB	64 GB
Memória virtual	64 TB	64 TB	64 TB	64 TB
Cache	512 kB L2	256 kB L2	2 MB L2	1,5 MB L2/15 MB L3
Número de cores	1	1	2	6

Atividade

Projeto de Upgrade de Computadores

Cenário 1 — PC Gamer

Situação

Um computador está apresentando:

- travamentos em jogos;
- carregamento muito lento;
- demora para iniciar o Windows.

Configuração atual

Componente	Configuração
CPU	Intel i5 antigo
RAM	8 GB DDR3
Armazenamento	HD 1 TB
GPU	GTX 1660

Orçamento

R\$ 800

Cenário 2 — Notebook para trabalho

Situação

Notebook usado para:

- Chrome com muitas abas;
- planilhas;
- reuniões online.

O sistema trava frequentemente.

Configuração atual

Componente	Configuração
RAM	4 GB
Armazenamento	HD 500 GB
CPU	i3

Orçamento

R\$ 500

Cenário 3 — Laboratório de IA

Situação

Um grupo de pesquisa precisa melhorar um computador para:

- treinar modelos de IA;
- processar muitos dados;
- trabalhar com imagens.

Configuração atual

Componente	Configuração
RAM	16 GB
SSD	SATA
GPU	RTX 3060

Orçamento

R\$ 2000

Cenário 4 — Servidor de empresa

Situação

Servidor de arquivos corporativos:

- lento;
- risco de perda de dados;
- muitos acessos simultâneos.

Configuração atual

Componente	Configuração
Armazenamento	1 HD
RAM	8 GB
CPU	Xeon

Orçamento

R\$ 1500